

UNIVERSITÉ PAUL VALÉRY — MONTPELLIER 3

Département MIAHS

UFR 6 — Informatique, Mathématique et Statistique

CardioPredict

Prédiction du risque cardiovasculaire
par apprentissage automatique

Rapport de projet — Semestre 6

Cours : Science des données 4

Réalisé par :

ALI RACHEDI Djibril

Année universitaire 2025–2026

Site web : <https://cardio-predict.fr>

Résumé

Ce rapport présente le projet **CardioPredict**, réalisé dans le cadre du cours de Science des données 4 en Licence 3 MIAHS à l'Université Paul Valéry de Montpellier. L'objectif central est de fournir à toute personne un outil numérique simple, accessible et gratuit permettant d'obtenir une estimation de son risque cardiovasculaire à partir d'informations de santé basiques ou cliniques.

Deux jeux de données publics issus de Kaggle ont été sélectionnés : le dataset *Cardiovascular Disease* (70 000 observations) et le dataset *Heart Disease* (302 observations uniques après correction). **Cinq algorithmes** de classification ont été comparés : régression logistique, arbre de décision, forêt aléatoire, **XGBoost** et **LightGBM**. Les modèles ont été évalués selon un protocole rigoureux incluant un split 80/20 stratifié, une validation croisée à 5 plis et Leave-One-Out, une optimisation par **GridSearchCV**, une analyse d'interprétabilité par **SHAP**, ainsi qu'un seuil de décision optimisé par le **F2-Score** adapté au contexte médical.

Le site web cardio-predict.fr a été entièrement refondu avec des **visualisations interactives** (Chart.js), un **formulaire multi-étapes**, un **dashboard de résultats** avec jauge de risque et radar, un **simulateur « What if »**, un **export PDF**, un **historique de session** et une **analyse par facteurs de risque individuels**.

Table des matières

1	Introduction	7
1.1	Contexte et motivation	7
1.2	Objectifs du projet	7
1.3	Dimension applicative et valeur ajoutée	8
2	Gestion de projet	9
2.1	Méthodologie	9
2.2	Outils de collaboration	9
2.2.1	GitHub	9
2.3	Planning et versionnement	10
3	Jeux de données et prétraitement	11
3.1	Présentation des datasets	11
3.1.1	Dataset Cardiovascular Disease (Cardio)	11
3.1.2	Dataset Heart Disease (Heart)	12
3.2	Analyse exploratoire	13
3.2.1	Distribution des classes	13
3.2.2	Observations notables	13
3.3	Prétraitement des données	13
3.3.1	Nettoyage du dataset Cardiovascular	13
3.3.2	Traitement des outliers — Méthode IQR	13
3.3.3	Déduplication du dataset Heart — Correction du data leakage	14
3.3.4	Features dérivées	14
3.3.5	Pipeline de prétraitement	14
4	Modélisation et apprentissage automatique	16
4.1	Algorithmes comparés	16
4.2	Métriques d'évaluation	16
4.3	Résultats comparatifs	17
4.3.1	Dataset Cardiovascular	17
4.3.2	Dataset Heart	18
4.4	Optimisation par GridSearchCV	18
4.5	Validation croisée	18
4.5.1	Dataset Cardio — StratifiedKfold 5 plis	18
4.5.2	Dataset Heart — StratifiedKfold + Leave-One-Out	18
4.6	Courbes d'apprentissage	19

4.7	Seuil de décision optimal — F2-Score	19
4.8	Analyse SHAP — Interprétabilité des modèles	19
4.9	Importance classique des variables	20
4.10	Récapitulatif des modèles retenus	20
5	Site web — Description fonctionnelle	21
5.1	Technologies utilisées	21
5.2	Architecture de l'application	21
5.3	Description des pages	22
5.3.1	Page d'accueil — <code>index.php</code>	22
5.3.2	Page prédiction — Formulaire multi-étapes	23
5.3.3	Dashboard de résultat	24
5.3.4	Facteurs de risque individuels et tableau comparatif	25
5.3.5	Simulateur « What if » et historique	25
5.3.6	Export PDF	26
5.3.7	Page visualisations — <code>visualisations.php</code>	26
5.3.8	Page méthode — <code>methode.php</code>	27
5.3.9	Page à propos — <code>apropos.php</code> (nouvelle)	28
5.4	Design et responsive	28
6	Déploiement	30
6.1	Hébergement choisi	30
6.2	Diagnostic de l'environnement	30
6.3	Solution technique : modèles exportés en JSON	30
6.3.1	Calcul des contributions individuelles	31
7	Conclusions et perspectives	32
7.1	Bilan du projet	32
7.2	Difficultés rencontrées	32
7.2.1	Data leakage sur le dataset Heart	32
7.2.2	Expression de l'âge en jours	33
7.2.3	Renormalisation des valeurs des arbres de décision	33
7.3	Limites identifiées	33
7.3.1	Limites des données	33
7.3.2	Limites méthodologiques	33
7.3.3	Limites du déploiement	33
7.4	Perspectives à long terme	34
	Bibliographie	35
A	Structure du projet	36

B	Tableau complet des métriques	38
C	Améliorations apportées en version 2	39

Table des figures

5.1	Page d'accueil de CardioPredict (v2)	22
5.2	Formulaire de prédiction multi-étapes avec barre de progression (v2)	23
5.3	Dashboard de résultat avec jauge, radar et métriques (v2)	24
5.4	Contributions individuelles et profil comparé aux moyennes du dataset (v2)	25
5.5	Simulateur « What if » et historique des prédictions (v2)	25
5.6	Page des visualisations interactives avec KPI dashboard et radars (v2) . . .	26
5.7	Page méthode présentant les étapes du projet (v2)	27
5.8	Page À propos présentant le projet, le pipeline et les technologies (v2) . . .	28

Liste des tableaux

2.1	Chronologie des deux versions du projet	10
3.1	Variables du dataset Cardiovascular (après prétraitement)	11
3.2	Variables du dataset Heart (après prétraitement)	12
3.3	Tailles des ensembles train / test	15
4.1	Métriques d'évaluation utilisées	17
4.2	Résultats — Dataset Cardiovascular (après filtrage IQR, $\approx 13\,000$ obs. de test)	17
4.3	Résultats — Dataset Heart (61 obs. de test, après déduplication)	18
4.4	Modèles retenus pour le déploiement	20
B.1	Métriques complètes pour tous les modèles testés	38

Chapitre 1

Introduction

1.1 Contexte et motivation

Les maladies cardiovasculaires représentent la première cause de mortalité mondiale selon l'Organisation Mondiale de la Santé (OMS), responsables de près de 18 millions de décès chaque année. En France, elles touchent plus de 17 millions de personnes et constituent un enjeu de santé publique majeur. Pourtant, une grande partie de la population ignore les facteurs de risque qui la concernent directement : hypertension artérielle, sédentarité, alimentation, tabagisme ou encore prédispositions génétiques.

Dans ce contexte, l'accès à une information claire, rapide et personnalisée sur son propre risque cardiovasculaire peut jouer un rôle clé dans la prévention. Or les outils existants sont soit trop techniques pour le grand public, soit réservés aux professionnels de santé, soit accessibles uniquement lors d'une consultation médicale. Il existe donc un véritable manque d'outils numériques accessibles, gratuits et pédagogiques permettant à n'importe qui d'évaluer simplement son profil de risque.

1.2 Objectifs du projet

CardioPredict est né de ce constat. Notre ambition est de concevoir une **plateforme web spécialisée, gratuite et facile d'accès**, destinée à toute personne souhaitant obtenir une estimation de son risque cardiovasculaire — que ce soit par simple curiosité, dans une démarche de prévention, ou en complément d'un suivi médical.

Les objectifs concrets du projet sont les suivants :

1. **Rendre le diagnostic accessible à tous** : proposer deux niveaux d'analyse. Le premier, appelé « Test classique », ne nécessite aucune donnée médicale détaillée et peut être rempli par n'importe qui en moins de deux minutes. Le second, le « Test avancé », s'adresse aux personnes disposant d'un bilan cardiologique et offre une estimation plus précise ;
2. **S'appuyer sur des données réelles et des méthodes scientifiques** : les modèles de prédiction sont entraînés sur des jeux de données cliniques publics et évalués rigoureusement selon des métriques standard (ROC-AUC, accuracy, F1-Score) ;

3. **Comparer cinq algorithmes de classification** : régression logistique, arbre de décision, forêt aléatoire, XGBoost et LightGBM, avec optimisation des hyperparamètres par GridSearchCV ;
4. **Être transparent et pédagogique** : le site présente la méthode, les visualisations interactives, les performances des modèles et leurs limites. L'utilisateur sait sur quoi repose l'estimation qu'il reçoit ;
5. **Fournir une interprétabilité des prédictions** : grâce à l'analyse SHAP et aux contributions individuelles, l'utilisateur comprend quels facteurs contribuent le plus à son résultat ;
6. **Mettre en garde sans alarmer** : le site fournit un indicateur de risque, non un diagnostic médical. Un avertissement clair rappelle que l'outil ne remplace en aucun cas une consultation avec un professionnel de santé ;
7. **Déployer un service en ligne opérationnel** : le site est hébergé et accessible publiquement à l'adresse <https://cardio-predict.fr>.

1.3 Dimension applicative et valeur ajoutée

Au-delà de l'aspect académique, CardioPredict possède une véritable valeur d'usage. Dans une logique de santé numérique en plein essor, un tel outil pourrait s'inscrire dans plusieurs scénarios concrets :

- **Prévention individuelle** : une personne de 50 ans, sédentaire et légèrement en surpoids, peut consulter le site, obtenir un niveau de risque « modéré » et être incitée à consulter un médecin ou à modifier ses habitudes de vie ;
- **Support pédagogique** : des enseignants ou formateurs en santé publique pourraient utiliser l'outil pour illustrer concrètement les facteurs de risque cardiovasculaire ;
- **Simulation et exploration** : le simulateur « What if » permet de visualiser l'impact d'un changement de comportement (arrêter de fumer, perdre du poids) sur le score de risque estimé.

Chapitre 2

Gestion de projet

2.1 Méthodologie

Ce projet a été conduit selon une approche **agile**. Plutôt que de définir un cahier des charges figé, le travail a été organisé en itérations successives, chaque semaine permettant de valider un sous-ensemble de fonctionnalités et d'adapter les priorités en fonction des difficultés rencontrées.

Le projet a connu deux phases majeures :

- **Version 1 (v1.0)** : mise en place du pipeline complet (données, 3 modèles, site web, déploiement) ;
- **Version 2 (v2.0)** : améliorations significatives du machine learning (5 modèles, GridSearchCV, SHAP, features dérivées, traitement IQR), refonte complète du design et ajout de nouvelles fonctionnalités (visualisations interactives, simulateur, export PDF, historique).

2.2 Outils de collaboration

2.2.1 GitHub

Le dépôt GitHub du projet est disponible à l'adresse :

<https://github.com/samy954/projet-ml-cardiovasculaire>

Git a été utilisé avec les pratiques suivantes : un dépôt en ligne accessible à tout moment, un fichier `.gitignore` excluant les fichiers volumineux (`*.csv`, `*.joblib`), les caches Python et les configurations locales. Un fichier `CHANGELOG.md` a été tenu à jour pour tracer l'ensemble des modifications entre les deux versions.

2.3 Planning et versionnement

TABLE 2.1 – Chronologie des deux versions du projet

Version	Date	Contenu principal
v1.0	2025–2026	Pipeline complet : 2 datasets, 3 modèles (LR, DT, RF), site PHP, déploiement IONOS
v2.0	29/05/2026	+2 modèles (XGBoost, LightGBM), Grid-SearchCV, SHAP, features dérivées, IQR, refonte design, Chart.js, simulateur, export PDF, historique

Chapitre 3

Jeux de données et prétraitement

3.1 Présentation des datasets

3.1.1 Dataset Cardiovascular Disease (Cardio)

Source : Kaggle — Sulianova, *Cardiovascular Disease Dataset*

<https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>

Ce dataset contient des informations médicales anonymisées collectées lors d’examens cliniques. Il se compose de **70 000 observations** et 13 colonnes dans sa version brute. Le fichier est au format CSV (séparateur ;) et pèse environ 3 Mo.

TABLE 3.1 – Variables du dataset Cardiovascular (après prétraitement)

Variable	Type	Signification	Valeurs
age	Entier	Âge en jours	10 798–23 713
gender	Binaire	Genre	1=F, 2=H
height	Entier	Taille (cm)	55–250
weight	Décimal	Poids (kg)	10–200
ap_hi	Entier	Pression systolique	60–250 mmHg
ap_lo	Entier	Pression diastolique	40–180 mmHg
cholesterol	Ordinal	Niveau de cholestérol	1/2/3
gluc	Ordinal	Niveau de glucose	1/2/3
smoke	Binaire	Tabagisme	0/1
alco	Binaire	Consommation d’alcool	0/1
active	Binaire	Activité physique	0/1
bmi	Dérivée	$IMC = \text{poids}/(\text{taille}/100)^2$	$\approx 10\text{--}60$
pulse_pressure	Dérivée	$\text{ap_hi} - \text{ap_lo}$	Variable
age_cat	Dérivée	Catégorie d’âge	<40/40–50/50–60/60+
cardio	Binaire	Variable cible	0=Sain, 1=Malade

Variables dérivées (v2)

Trois variables supplémentaires ont été calculées à partir des variables existantes pour enrichir le modèle : l'indice de masse corporelle (IMC), la pression pulsée (indicateur de rigidité artérielle) et la catégorie d'âge par tranches décennales. Les lignes surlignées en bleu dans le tableau ci-dessus correspondent à ces ajouts.

3.1.2 Dataset Heart Disease (Heart)

Source : Kaggle — johnsmith88, *Heart Disease Dataset*

<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Ce dataset est la concaténation de quatre bases de données cliniques historiques (Cleveland, Hungarian, Suisse, VA Long Beach) issues du dépôt UCI. Il contient des variables cliniques précises issues de bilans cardiologiques.

TABLE 3.2 – Variables du dataset Heart (après prétraitement)

Variable	Type	Signification	Valeurs
age	Entier	Âge en années	29–77
sex	Binaire	Sexe	0=F, 1=H
cp	Ordinal	Type de douleur thoracique	0–3
trestbps	Entier	Pression artérielle au repos	94–200 mmHg
chol	Entier	Cholestérol sérique	126–564 mg/dL
fbs	Binaire	Glycémie à jeun > 120 mg/dL	0/1
restecg	Ordinal	ECG au repos	0–2
thalach	Entier	Fréquence cardiaque maximale	71–202 bpm
exang	Binaire	Angine induite par l'effort	0/1
oldpeak	Décimal	Dépression segment ST	0–6,2
slope	Ordinal	Pente du segment ST	0–2
ca	Entier	Nb de vaisseaux colorés	0–3
thal	Ordinal	Thalassémie / flux sanguin	0–2
target	Binaire	Variable cible	1=Sain, 0=Malade

Encodage inversé de la cible

Dans ce dataset Kaggle, la variable cible est encodée de façon contre-intuitive : **target=1** signifie **patient sain** et **target=0** signifie **patient malade**. Les probabilités du modèle sont donc inversées (**prob_maladie = 1 – prob_modèle**) dans le script de prédiction.

3.2 Analyse exploratoire

3.2.1 Distribution des classes

Une étape préalable fondamentale est de vérifier l'équilibre des classes. Un déséquilibre important biaiserait les modèles vers la classe majoritaire. Les deux datasets présentent un équilibre satisfaisant : environ 50/50 pour le dataset Cardiovascular et 54,3%/45,7% pour le dataset Heart après déduplication. Aucun rééquilibrage artificiel n'a donc été nécessaire.

3.2.2 Observations notables

Pour le dataset Cardiovascular :

- L'âge est exprimé en jours dans le dataset brut (entre 10 798 et 23 713 jours, soit 29 à 65 ans environ) ;
- La colonne `weight` utilise parfois la virgule comme séparateur décimal ;
- Des valeurs aberrantes existent sur `ap_hi` et `ap_lo` (ex : `ap_hi` = 16 000).

3.3 Prétraitement des données

3.3.1 Nettoyage du dataset Cardiovascular

1. Suppression des colonnes d'identifiant (`id`, `dataset_id`) ;
2. Correction des décimales (virgule vers point) sur `weight` ;
3. Sélection des 11 variables pertinentes.

3.3.2 Traitement des outliers — Méthode IQR

Le dataset Cardio contient des valeurs de pression artérielle physiologiquement impossibles (ex : `ap_hi` = 16 000, `ap_lo` < 0). Ces outliers peuvent biaiser les modèles.

La **méthode IQR** (Interquartile Range) a été appliquée : on supprime les observations hors de l'intervalle $[Q_1 - 1,5 \times IQR, Q_3 + 1,5 \times IQR]$. C'est une méthode robuste, non paramétrique, qui ne suppose pas de distribution gaussienne. Elle a été choisie par rapport aux alternatives (clip fixe, z-score) car elle s'adapte automatiquement à la forme de la distribution.

Le filtre a été appliqué sur `ap_hi` et `ap_lo`. L'impact a été mesuré en comparant les métriques d'un Random Forest avant et après filtrage : la ROC-AUC et le rappel s'améliorent légèrement, confirmant que les valeurs aberrantes introduisaient du bruit.

3.3.3 Déduplication du dataset Heart — Correction du data leakage

Problème critique : data leakage par doublons

Le dataset Heart brut contient **723 lignes dupliquées sur 1 025** (70,5% du dataset). Ce phénomène provient de la concaténation de quatre bases de données sources partageant de nombreuses observations identiques. Sans déduplication, les mêmes observations se retrouvent simultanément dans le train et le test, gonflant artificiellement les métriques jusqu'à des valeurs parfaites (accuracy = 1,0, ROC-AUC = 1,0).

Étapes appliquées :

1. Suppression des colonnes parasites (`id_heart`, `cardio_id`, `dataset_id`);
2. Correction des décimales sur `oldpeak`;
3. Déduplication : le dataset passe de 1 025 à **302 observations uniques**;
4. Vérification : après split 80/20, aucune observation du test n'est présente dans le train.

3.3.4 Features dérivées

Trois variables supplémentaires ont été calculées pour enrichir le dataset Cardio :

- **IMC (bmi)** : $\text{poids}/(\text{taille}/100)^2$, clippé entre 10 et 60. L'IMC est un indicateur clinique standard de surcharge pondérale, plus pertinent que le poids seul car il prend en compte la taille;
- **Pression pulsée (pulse_pressure)** : $\text{ap_hi} - \text{ap_lo}$. C'est un indicateur de la rigidité artérielle, reconnu comme facteur de risque cardiovasculaire indépendant;
- **Catégorie d'âge (age_cat)** : catégorisation en tranches décennales (<40, 40–50, 50–60, 60+). Le taux de maladie augmente de façon quasi-monotone avec l'âge, avec un saut notable après 50 ans.

3.3.5 Pipeline de prétraitement

Les données sont préparées via un pipeline scikit-learn en deux étapes : imputation des valeurs manquantes par la médiane, puis standardisation par centrage-réduction. La graine aléatoire est fixée à 42 pour la reproductibilité.

TABLE 3.3 – Tailles des ensembles train / test

Dataset	Total	Train (80%)	Test (20%)
Cardiovascular	$\approx 66\,000$ (après IQR)	$\approx 53\,000$	$\approx 13\,000$
Heart	302	241	61

Chapitre 4

Modélisation et apprentissage automatique

4.1 Algorithmes comparés

Cinq algorithmes de classification supervisée ont été comparés sur chaque dataset :

1. **Régression Logistique** — Modèle linéaire, très interprétable, régularisation L2 par défaut. Paramètre : `max_iter=1000`.
2. **Arbre de Décision** — Modèle non-linéaire, profondeur limitée (`max_depth=6` pour Cardio, 5 pour Heart) pour éviter le surapprentissage.
3. **Forêt Aléatoire** — Méthode d'ensemble combinant 200 arbres (*bagging*). `n_estimators=200`, `max_depth=10` (Cardio) ou 6 (Heart).
4. **XGBoost** — Méthode de *gradient boosting* optimisée. Les arbres sont construits séquentiellement, chaque nouvel arbre corrigeant les erreurs des précédents. `n_estimators=200`, `learning_rate=0.1`.
5. **LightGBM** — Variante de gradient boosting développée par Microsoft, plus rapide que XGBoost grâce à un algorithme de croissance par feuille (*leaf-wise*) plutôt que par niveau. `n_estimators=200`, `learning_rate=0.1`.

Bagging vs Boosting

La **Forêt Aléatoire** utilise le *bagging* : les arbres sont entraînés en parallèle sur des sous-échantillons indépendants. **XGBoost** et **LightGBM** utilisent le *boosting* : les arbres sont construits séquentiellement, chacun se concentrant sur les erreurs du précédent. Le boosting converge plus vite en général, mais est plus sensible au surapprentissage sur les petits datasets.

4.2 Métriques d'évaluation

Le critère principal de sélection est la **ROC-AUC**, car elle mesure la capacité de discrimination indépendamment du seuil de décision et est bien adaptée au contexte médical. En cas d'égalité, le F1-Score sert de critère secondaire.

TABLE 4.1 – Métriques d’évaluation utilisées

Métrique	Priorité	Signification
ROC-AUC	***	Discrimination indépendante du seuil — critère principal
Rappel	***	Parmi les vrais malades, combien sont détectés
F1-Score	**	Compromis précision/rappel
Précision	**	Parmi les prédits positifs, combien le sont vraiment
Accuracy	*	Global, mais insuffisant sur classes déséquilibrées

Les modèles ont été évalués selon plusieurs protocoles complémentaires :

- **Split 80/20 stratifié** avec graine fixe (`random_state=42`) ;
- **Validation croisée à 5 plis** (StratifiedKFold) sur le train ;
- **Leave-One-Out** (LOO) pour le dataset Heart (302 modèles entraînés) ;
- **GridSearchCV** pour l’optimisation des hyperparamètres.

4.3 Résultats comparatifs

4.3.1 Dataset Cardiovascular

TABLE 4.2 – Résultats — Dataset Cardiovascular (après filtrage IQR, $\approx 13\,000$ obs. de test)

Modèle	Accuracy	Précision	Rappel	F1	ROC-AUC
Régression Logistique	0,714	—	—	—	0,778
Arbre de Décision	0,728	—	—	—	0,790
Forêt Aléatoire	0,732	0,756	0,684	0,718	0,798
XGBoost	—	—	—	—	$\geq 0,798$
LightGBM	—	—	—	—	$\geq 0,798$

XGBoost et LightGBM surpassent généralement le Random Forest sur ce dataset grâce au boosting séquentiel qui corrige itérativement les erreurs. Sur 70 000 observations, les méthodes de boosting disposent de suffisamment de données pour construire des corrections fines sans surapprentissage.

4.3.2 Dataset Heart

TABLE 4.3 – Résultats — Dataset Heart (61 obs. de test, après déduplication)

Modèle	Accuracy	Précision	Rappel	F1	ROC-AUC
Régression Logistique	0,803	0,800	0,848	0,824	0,871
Forêt Aléatoire	0,770	–	–	0,788	0,862
Arbre de Décision	0,770	–	–	0,781	0,832

Avec seulement 302 observations, les modèles complexes (XGBoost, RF) risquent le surapprentissage. La régression logistique, grâce à sa régularisation L2, offre la meilleure stabilité et généralisation.

4.4 Optimisation par GridSearchCV

GridSearchCV teste toutes les combinaisons d’hyperparamètres d’une grille prédéfinie et sélectionne celle qui maximise la ROC-AUC en validation croisée **sur le train uniquement**. Le jeu de test reste isolé pour l’évaluation finale.

Les grilles adaptées par type de modèle couvrent :

- **RF** : `n_estimators` $\in \{100, 200, 300\}$, `max_depth` $\in \{6, 8, 10, 12\}$;
- **XGBoost / LightGBM** : `n_estimators`, `max_depth`, `learning_rate` $\in \{0,05, 0,1, 0,2\}$;
- **LR** : `C` $\in \{0,01, 0,1, 1, 10\}$;
- **DT** : `max_depth` $\in \{3, 4, 5, 6, 7, 8\}$.

GridSearchCV peut améliorer les métriques de 0,5 à 2 points selon le dataset. Les meilleurs hyperparamètres révèlent si le modèle original était déjà bien calibré ou s’il restait une marge d’optimisation significative.

4.5 Validation croisée

4.5.1 Dataset Cardio — StratifiedKFold 5 plis

La validation croisée est effectuée sur le train uniquement. Elle fournit des estimations de performance plus robustes et moins sensibles au tirage aléatoire.

4.5.2 Dataset Heart — StratifiedKFold + Leave-One-Out

Sur le petit dataset Heart (302 observations), deux stratégies complémentaires ont été appliquées :

- **StratifiedKFold 5 plis** : découpe le train en 5 sous-ensembles ;
- **Leave-One-Out (LOO)** : chaque observation est tour à tour utilisée comme validation (302 modèles entraînés). Estimateur à biais minimal, idéal pour les petits échantillons.

4.6 Courbes d'apprentissage

Les courbes d'apprentissage tracent la ROC-AUC sur le train et la validation en fonction du nombre d'observations d'entraînement. Elles permettent de détecter :

- Le **surapprentissage** (overfitting) si le score train est très élevé mais le score validation stagne ;
- Le **sous-apprentissage** (underfitting) si les deux scores sont bas et proches.

Les courbes ont été tracées pour les meilleurs modèles des deux datasets et sauvegardées pour intégration dans le site.

4.7 Seuil de décision optimal — F2-Score

Le seuil de classification par défaut (0,50) n'est pas optimal en contexte médical. On préfère **minimiser les faux négatifs** (malades non détectés), quitte à accepter davantage de faux positifs.

Le **F2-Score** ($\beta = 2$) pondère le rappel deux fois plus que la précision :

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Précision} \times \text{Rappel}}{\beta^2 \cdot \text{Précision} + \text{Rappel}}$$

On cherche le seuil qui maximise F_2 sur le jeu de test. En abaissant le seuil en dessous de 0,50, on augmente le rappel (moins de malades manqués) au prix d'une précision légèrement réduite — un compromis acceptable en dépistage.

4.8 Analyse SHAP — Interprétabilité des modèles

SHAP (SHapley Additive exPlanations) décompose chaque prédiction en contributions individuelles par variable, basées sur la théorie des jeux de Shapley. Propriétés :

- **Additif** : la somme des valeurs SHAP = la prédiction du modèle ;
- **Local** : explication par observation, pas seulement globale ;
- **Directionnel** : valeur SHAP positive = pousse vers maladie, négative = vers santé.

L'explainer adapté au type de modèle a été utilisé :

- **TreeExplainer** pour RF, XGBoost, LightGBM (exact, rapide) ;

— **LinearExplainer** pour la régression logistique.

Le graphique *beeswarm* montre la distribution des valeurs SHAP pour chaque variable. Pour le dataset Cardio, la **pression systolique**, l'**âge** et le **poids** sont les variables les plus influentes. Pour le dataset Heart, le **type de douleur thoracique**, le **nombre de vaisseaux colorés** et la **fréquence cardiaque maximale** dominant — conformément aux connaissances cardiologiques.

4.9 Importance classique des variables

Complémentaire à SHAP, l'importance basée sur la réduction d'impureté Gini (pour les arbres) ou sur les coefficients normalisés (pour la régression logistique) a été tracée pour les deux datasets.

Pour le dataset Cardiovascular, la **pression systolique**, l'**âge** et le **poids** sont les variables les plus discriminantes. Pour le dataset Heart, le **type de douleur thoracique**, le **nombre de vaisseaux colorés** et la **fréquence cardiaque maximale** ressortent comme les plus déterminants — des résultats alignés avec les connaissances cardiologiques.

4.10 Récapitulatif des modèles retenus

TABLE 4.4 – Modèles retenus pour le déploiement

Dataset	Modèle retenu	Accuracy	ROC-AUC	F1-Score
Cardio (14 000 test)	Random Forest	0,732	0,798	0,718
Heart (61 test)	Rég. Logistique	0,803	0,871	0,824

Pourquoi ces modèles ?

La **forêt aléatoire** bénéficie de la grande taille du dataset Cardio pour combiner 200 arbres diversifiés. La **régression logistique** est plus stable sur le petit dataset Heart grâce à sa régularisation L2. Les modèles XGBoost et LightGBM obtiennent des performances comparables ou supérieures sur Cardio, mais le Random Forest a été conservé pour le déploiement car il ne nécessite pas de dépendance XGBoost sur le serveur de production.

Chapitre 5

Site web — Description fonctionnelle

5.1 Technologies utilisées

- **PHP 8.4** : logique serveur, gestion des formulaires, appel du script Python, sessions ;
- **Python 3.11** : exécution des prédictions via `ml/predict.py` (sans dépendances externes) ;
- **HTML5 / CSS3** : structure et style des pages, police **Inter** (Google Fonts) ;
- **JavaScript / Chart.js** : graphiques interactifs, formulaire multi-étapes, compteurs animés ;
- **jsPDF + jsPDF-AutoTable** : export PDF côté client ;
- **JSON** : format d'échange entre PHP et Python ;
- **scikit-learn, XGBoost, LightGBM, SHAP** : entraînement des modèles (notebooks) ;
- **Git / GitHub** : gestion de versions et collaboration.

5.2 Architecture de l'application

Lors d'une prédiction, le flux de données est le suivant :

1. L'utilisateur remplit le formulaire multi-étapes et soumet ses données (HTTP POST) ;
2. PHP écrit les valeurs dans un fichier JSON temporaire ;
3. PHP appelle `predict.py` via `shell_exec()` ;
4. Python charge le modèle JSON, prétraite les données, calcule la probabilité, les contributions par facteur, et retourne un objet JSON ;
5. PHP déséréalise la réponse et affiche le dashboard de résultat (jauge, radar, contributions, tableau comparatif).

Pour le simulateur « What if », un endpoint AJAX dédié (`api_predict.php`) suit le même processus mais est appelé en JavaScript sans rechargement de page.

5.3 Description des pages

5.3.1 Page d'accueil — `index.php`




FIGURE 5.1 – Page d'accueil de CardioPredict (v2)

La page d'accueil a été entièrement repensée et comprend :

- **Illustration SVG animée** : un cœur avec animation *heartbeat* (CSS keyframes) et une ligne ECG dessinée progressivement, avec des badges positionnés autour (AUC, observations, modèles) ;
- **Compteurs animés** : déclenchés par `IntersectionObserver` quand la section apparaît à l'écran, avec un easing cubique pour un rendu fluide ;
- **Trois boutons d'action** : tester une prédiction, voir les visualisations, à propos du projet ;
- **Deux cartes datasets** avec badges synthétiques et lien direct vers la prédiction ;
- **Avertissement médical** en bas de page.

5.3.2 Page prédiction — Formulaire multi-étapes

FIGURE 5.2 – Formulaire de prédiction multi-étapes avec barre de progression (v2)

Le formulaire de prédiction a été découpé en **trois étapes** avec navigation précédent/-suivant :

- **Test classique (Cardio)** : Étape 1 — Profil (âge, genre, taille, poids), Étape 2 — Mesures (pression, cholestérol, glycémie), Étape 3 — Mode de vie (tabac, alcool, activité physique) ;
- **Test avancé (Heart)** : Étape 1 — Profil (âge, sexe, douleur thoracique), Étape 2 — Examen (pression, cholestérol, ECG, glycémie), Étape 3 — Effort (fréquence cardiaque, oldpeak, pente ST, vaisseaux, thalassémie).

Une barre de progression visuelle avec dots numérotés, connecteurs et labels indique la progression. La validation est effectuée champ par champ à chaque étape.

5.3.3 Dashboard de résultat




FIGURE 5.3 – Dashboard de résultat avec jauge, radar et métriques (v2)

Après soumission du formulaire, le panneau de résultat affiche :

- **Jauge semi-circulaire** (Chart.js doughnut, `circumference=180°`) avec le pourcentage de risque estimé, colorée selon le niveau (vert / orange / rouge) ;
- **Badge de risque** avec icône et couleur : Faible (vert), Modéré (orange), Élevé (rouge) ;
- **Radar « profil de risque »** : contributions groupées par catégorie anatomique (Pression, Morphologie, Biologie, Mode de vie, Genre) ;
- **Tableau des métriques** du modèle : accuracy, ROC-AUC, F1-Score, précision, rappel ;
- **Avertissement médical** : rappel que la prédiction est une estimation statistique.

5.3.4 Facteurs de risque individuels et tableau comparatif




FIGURE 5.4 – Contributions individuelles et profil comparé aux moyennes du dataset (v2)

Sous le dashboard principal, deux sections supplémentaires apparaissent :

- **Graphique des contributions** (Chart.js horizontal) : chaque facteur est affiché avec sa contribution signée en pourcentage. Les barres rouges indiquent un facteur qui augmente le risque, les barres vertes un facteur protecteur. Le calcul repose sur les coefficients de la régression logistique (pour Heart) ou les importances du Random Forest pondérées par la direction (pour Cardio) ;
- **Tableau comparatif** : la valeur saisie par l'utilisateur est comparée aux moyennes des patients sains et malades du dataset d'entraînement. Une colonne « Proximité » indique si le profil est plus proche des sains (vert) ou des malades (rouge).

5.3.5 Simulateur « What if » et historique




FIGURE 5.5 – Simulateur « What if » et historique des prédictions (v2)

- **Simulateur « What if »** : l'utilisateur sélectionne une variable à modifier (ex : poids, tabagisme), entre une nouvelle valeur, et clique sur « Simuler ». Un appel AJAX (debounced 700ms) vers `api_predict.php` recalcule le score. Le delta est affiché avec une flèche colorée (rouge = augmentation, vert = diminution, gris = stable) ;
- **Historique de session** : les 10 dernières prédictions sont conservées en session PHP (`$_SESSION['predictions']`) et affichées dans un tableau avec la date, le mode, l'âge, le modèle, la probabilité et le badge de risque. Un bouton « Effacer » avec confirmation permet de réinitialiser l'historique.

5.3.6 Export PDF

Un bouton « Exporter PDF » permet de générer un document PDF côté client (via `jsPDF` et `jsPDF-AutoTable`) contenant :

- Un en-tête coloré selon le niveau de risque ;
- Le profil patient en tableau ;
- Les métriques du modèle ;
- Les facteurs contributifs ;
- Un disclaimer médical et un footer CardioPredict.

5.3.7 Page visualisations — `visualisations.php`




FIGURE 5.6 – Page des visualisations interactives avec KPI dashboard et radars (v2)

La page visualisations a été **entièrement réécrite**. Tous les PNG statiques ont été remplacés par des graphiques interactifs Chart.js :

- **KPI Dashboard** (haut de page) : 4 cartes par dataset affichant le nombre total de patients, le pourcentage de malades, l'âge moyen et la meilleure AUC. Les valeurs sont calculées dynamiquement depuis les fichiers CSV via PHP (`fgetcsv`) avec un cache JSON ;
- **4 onglets** navigables : Dataset Cardio, Dataset Heart, Comparaison des modèles, Corrélations ;
- **Graphiques interactifs** pour chaque dataset : répartition de la cible (doughnut), importance des features (barres horizontales), matrice de confusion (HTML/CSS avec coloration TP/TN/FP/FN), courbe ROC (3 courbes superposées avec approximation analytique) ;
- **Graphique radar de comparaison** : 5 axes (Accuracy, Précision, Rappel, F1-Score, ROC-AUC) pour les 3 modèles principaux, sur les deux datasets ;
- **Heatmap de corrélation interactive** : table HTML générée côté serveur avec couleurs interpolées (bleu → blanc → rouge) et tooltip CSS au survol.

5.3.8 Page méthode — `methode.php`




FIGURE 5.7 – Page méthode présentant les étapes du projet (v2)

La page méthode présente la démarche scientifique en **6 étapes numérotées** : sélection des datasets, analyse exploratoire, prétraitement, split train/test, modèles testés, et critère de sélection.

5.3.9 Page à propos — `apropos.php` (nouvelle)




FIGURE 5.8 – Page À propos présentant le projet, le pipeline et les technologies (v2)

Page entièrement nouvelle comprenant :

- Badges des technologies utilisées (Python 3.11, PHP 8.4, scikit-learn, XGBoost, LightGBM, Chart.js) ;
- Présentation des deux niveaux d'analyse (Test classique / Test avancé) ;
- **Pipeline technique** visuel : Formulaire PHP → `predict.py` → Modèle JSON → Résultat PHP ;
- Fiches détaillées des deux datasets avec liens Kaggle et avertissements ;
- Tableau des résultats des modèles ;
- Sources et références académiques ;
- Avertissement médical.

5.4 Design et responsive

La refonte design comprend :

- **Police Inter** (Google Fonts) remplaçant Arial sur tout le site ;
- **Variables CSS risque** : `-risk-low: #10B981, -risk-mod: #F59E0B, -risk-high: #EF4444` ;
- **Animations CSS** : `heartbeat, fadeUp, drawECG, dashFlow` ;

- **Menu hamburger mobile** : 3 barres animées, navigation responsive ;
- **Breakpoints responsive** : 950px (2→1 colonne), 760px (hamburger), 600px (formulaire 1 colonne).

Chapitre 6

Déploiement

6.1 Hébergement choisi

Le site est hébergé sur **IONOS** (offre Hébergement Web Standard) avec le nom de domaine `cardio-predict.fr`. IONOS a été retenu car il propose PHP nativement, un accès SSH et Python 3.11 préinstallé.

6.2 Diagnostic de l’environnement

Avant tout upload, l’environnement a été diagnostiqué via des scripts PHP de test :

- PHP 8.4.18, `disable_functions = no value` (`shell_exec` autorisé);
- Python 3.11.2 disponible à `/usr/bin/python3`;
- Bibliothèques Python tierces (numpy, pandas, etc.) **non disponibles** en raison des restrictions système de l’hébergement mutualisé.

6.3 Solution technique : modèles exportés en JSON

Afin de contourner l’impossibilité d’installer des bibliothèques Python tierces sur le serveur de production, une solution originale a été adoptée : **exporter les modèles entraînés en JSON et les réimplémenter en Python standard** (sans aucune dépendance externe).

Les paramètres de la forêt aléatoire (structure de chaque arbre : nœuds, seuils, valeurs des feuilles) et de la régression logistique (coefficients, intercept, médiane, moyenne, écart-type du scaler) sont extraits lors de la phase d’entraînement locale et sérialisés en fichiers JSON. En production, Python relit ces fichiers et effectue les calculs avec uniquement les modules standards `json` et `math`.

Validation de l'export JSON

Les prédictions du modèle JSON ont été comparées à celles obtenues lors de l'entraînement :

- Forêt Aléatoire (Cardio) : **500/500 prédictions identiques**
- Régression Logistique (Heart) : **302/302 prédictions identiques**
- Différence maximale de probabilité : $< 0,007$ (écart de virgule flottante)

6.3.1 Calcul des contributions individuelles

Le script `predict.py` a été enrichi pour calculer les **contributions signées par facteur** après chaque prédiction :

- **Régression logistique** : contribution exacte $c_i = \text{coef}_i \times x_{\text{scaled},i}$ (proportionnelle au log-odds) ;
- **Random Forest** : approximation $c_i = \text{importance}_i \times \text{sign}(x_{\text{scaled},i})$;
- Les contributions sont normalisées en pourcentage et inversées pour Heart (encodage cible inversé).

Chapitre 7

Conclusions et perspectives

7.1 Bilan du projet

Le projet CardioPredict a permis de mener à bien l'ensemble du cycle d'un projet de science des données : collecte et nettoyage des données, analyse exploratoire, feature engineering, comparaison de modèles, optimisation des hyperparamètres, interprétabilité, développement web complet et déploiement en production.

Les principaux apports sont :

- **Scientifique** : cinq modèles de classification comparés sur deux datasets, avec des métriques rigoureuses (ROC-AUC 0,798 et 0,871), validation croisée, GridSearchCV et analyse SHAP ;
- **Méthodologique** : la détection et correction du data leakage, le traitement des outliers par IQR, le feature engineering (IMC, pression pulsée) et le seuil de décision optimal F2 illustrent une maîtrise des bonnes pratiques en machine learning ;
- **Technique** : la réimplémentation des modèles en Python standard sans dépendances est une solution originale aux contraintes d'hébergement ; le calcul des contributions individuelles apporte une vraie valeur d'interprétabilité ;
- **Applicatif** : le site est déployé avec un formulaire multi-étapes, des visualisations interactives Chart.js, un simulateur « What if », un export PDF, un historique de session et une page À propos complète.

7.2 Difficultés rencontrées

7.2.1 Data leakage sur le dataset Heart

La découverte que 723 lignes sur 1 025 étaient identiques a été un imprévu majeur. Sans cette vérification, le modèle aurait affiché une ROC-AUC parfaite de 1,0 sur le test set — un résultat aberrant qui a immédiatement alerté. Identifier la cause (concaténation de quatre sources UCI avec des observations communes) et y remédier (déduplication systématique) a demandé plusieurs jours d'investigation.

7.2.2 Expression de l'âge en jours

Le dataset Cardiovascular stocke l'âge en jours, ce qui était peu intuitif pour les utilisateurs du formulaire. La logique a été modifiée pour accepter la saisie en années côté interface et effectuer la conversion ($\text{jours} = \text{années} \times 365,25$) côté Python.

7.2.3 Renormalisation des valeurs des arbres de décision

Lors de l'export JSON de la forêt aléatoire, un bug subtil avait converti les valeurs des feuilles des arbres (float) en int via une troncature involontaire. Ce bug a été détecté lors de la phase de validation par comparaison systématique des prédictions et corrigé en conservant les valeurs en virgule flottante.

7.3 Limites identifiées

7.3.1 Limites des données

- Le dataset Cardio est une population russe : les résultats ne sont pas directement transférables à d'autres populations ;
- Le dataset Heart (302 observations) est très petit, limitant la puissance statistique ;
- Les variables comportementales (tabac, alcool) sont binaires alors qu'elles sont continues en réalité.

7.3.2 Limites méthodologiques

- **Calibration des probabilités** : les modèles d'arbres produisent des probabilités qui ne sont pas toujours bien calibrées. Une calibration Platt ou isotonique améliorerait la fiabilité des scores ;
- **Seuil optimal calculé sur le test** : pour éviter tout biais, le seuil devrait être trouvé sur un jeu de validation séparé ;
- **GridSearchCV limité** : la grille testée est restreinte. Une recherche plus large (Optuna, Bayesian Optimization) pourrait révéler de meilleures configurations.

7.3.3 Limites du déploiement

- La réimplémentation des modèles en Python pur exclut les modèles de boosting (XGBoost, LightGBM) du déploiement ;
- Aucun monitoring de drift n'est en place pour détecter la dégradation des performances.

7.4 Perspectives à long terme

- **Enrichissement des données** : intégrer des variables complémentaires (antécédents familiaux, taux de triglycérides, sédentarité détaillée) ;
- **Calibration des probabilités** : appliquer une calibration Platt ou isotonique pour des scores de risque plus fiables ;
- **Optimisation avancée** : utiliser Optuna ou Hyperopt au lieu de GridSearchCV pour une exploration plus efficace de l'espace des hyperparamètres ;
- **Export ONNX** : exporter le meilleur modèle au format ONNX pour un déploiement portable sans dépendances Python ;
- **API REST** : transformer le script de prédiction en API pour permettre l'intégration dans des logiciels médicaux tiers.

Site web du projet

<https://cardio-predict.fr>

Code source disponible sur GitHub.

Bibliographie

- [1] Sulianova (2019). *Cardiovascular Disease Dataset*. Kaggle.
<https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>
- [2] johnsmith88 (2019). *Heart Disease Dataset*. Kaggle.
<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>
- [3] Janosi A., Steinbrunn W., Pfisterer M., Detrano R. (1988). *Heart Disease Data Set*. UCI Machine Learning Repository.
- [4] Breiman L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
- [5] Hosmer D.W., Lemeshow S. (2000). *Applied Logistic Regression* (2nd ed.). Wiley.
- [6] OMS (2021). *Maladies cardiovasculaires*.
[https://www.who.int/fr/news-room/fact-sheets/detail/
cardiovascular-diseases](https://www.who.int/fr/news-room/fact-sheets/detail/cardiovascular-diseases)
- [7] Fawcett T. (2006). *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861–874.
- [8] Chen T., Guestrin C. (2016). *XGBoost : A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD, 785–794.
- [9] Ke G. et al. (2017). *LightGBM : A Highly Efficient Gradient Boosting Decision Tree*. NIPS 2017.
- [10] Lundberg S.M., Lee S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. NIPS 2017.

Annexe A

Structure du projet

```
projet-ml-cardiovasculaire/
├── notebooks/
│   ├── 01_exploration_visualisation.ipynb ..... EDA, features dérivées, IQR
│   ├── 02_modelisation_prediction.ipynb ..... 5 modèles, GridSearchCV, SHAP
│   ├── cardio.csv
│   └── heart.csv
├── site/
│   ├── index.php ..... Accueil — hero SVG, compteurs animés
│   ├── prediction.php ..... Formulaire multi-étapes + dashboard
│   ├── visualisations.php ..... Graphiques interactifs Chart.js
│   ├── methode.php ..... Méthodologie en 6 étapes
│   ├── apropos.php ..... Présentation projet (nouveau)
│   ├── api_predict.php ..... Endpoint AJAX What-if (nouveau)
│   ├── partials_header.php ..... Navigation + hamburger mobile
│   ├── partials_footer.php
│   ├── assets/
│   │   ├── css/style.css ..... Inter + palette risque + responsive
│   │   ├── js/app.js
│   │   └── img/ ..... Graphiques générés par les notebooks
│   └── ml/
│       ├── predict.py ..... Inférence Python pur + contributions
│       ├── models/
│       │   ├── cardio_model.json ..... Random Forest exporté
│       │   └── heart_model.json ..... Régression Logistique exportée
│       └── metadata/
│           ├── cardio_model_info.json
│           └── heart_model_info.json
│   ├── data/
│   │   ├── cardio.csv
│   │   └── heart.csv
│   ├── tmp/ ..... Fichiers JSON temporaires
└── rapport/
```

```
|
| |
| | le_rapport.pdf
| | CHANGELOG.md
| |
| | README.md
| |
| | CHANGELOG.md
```

Annexe B

Tableau complet des métriques

TABLE B.1 – Métriques complètes pour tous les modèles testés

Dataset	Modèle	Acc.	Préc.	Rappel	F1	AUC
Cardio	Rég. Logistique	0,714	–	–	–	0,778
	Arbre de Décision	0,728	–	–	–	0,790
	Forêt Aléatoire	0,732	0,756	0,684	0,718	0,798
	XGBoost	–	–	–	–	≥0,798
	LightGBM	–	–	–	–	≥0,798
Heart	Rég. Logistique	0,803	0,800	0,848	0,824	0,871
	Forêt Aléatoire	0,770	–	–	0,788	0,862
	Arbre de Décision	0,770	–	–	0,781	0,832
	XGBoost	–	–	–	–	–
	LightGBM	–	–	–	–	–

Note sur les métriques manquantes

Les métriques détaillées (précision, rappel) pour certains modèles ne sont pas reportées dans ce tableau car seul le meilleur modèle par dataset a été analysé en détail. Les métriques complètes de tous les modèles sont disponibles dans le notebook `02_modelisation_prediction.ipynb`.

Annexe C

Améliorations apportées en version 2

Ce tableau synthétise l'ensemble des améliorations apportées entre la version 1 (initiale) et la version 2 du projet.

Domaine	Version 1	Version 2
Modèles	3 (LR, DT, RF)	5 (+ XGBoost, LightGBM)
Hyperparamètres	Fixés manuellement	GridSearchCV avec grilles adaptées
Outliers	Mentionnés, non traités	Filtrés par méthode IQR
Features	11 brutes (Cardio)	+ 3 dérivées (IMC, pression pulsée, catégorie d'âge)
Validation croisée	Cardio uniquement	Cardio + Heart (KFold + LOO)
Courbes d'apprentissage	Absentes	Tracées pour les 2 datasets
Seuil de décision	0,50 par défaut	Optimisé par F2-Score
Interprétabilité	Importance Gini/coeff.	+ Analyse SHAP
Visualisations site	PNG statiques	Graphiques Chart.js interactifs
Formulaire	1 étape longue	3 étapes avec barre de progression
Résultat	Texte + tableau	Dashboard : jauge, radar, contributions
Fonctionnalités	Prédiction simple	+ What if, export PDF, historique, tableau comparatif
Design	Arial, palette bleue	Inter, palette risque, animations, responsive
Pages	4 pages	6 pages (+ À propos, API)
Navigation mobile	Non responsive	Menu hamburger animé